

Progetto di Introduzione alla Programmazione

Michele Corazza

Progetto

Il progetto è **di gruppo** (di 3-4 persone) e vi viene richiesto di crearlo usando un Jupyter notebook. Potete creare pacchetti e moduli per implementare alcune funzioni del progetto, ma il file principale deve essere un notebook. Dovrete inviare via e-mail (michele.corazza2@unibo.it) una settimana prima dell'esame un archivio zip che contene la cartella del progetto contenente tutto il codice e tutti i dati utilizzati. Il progetto verrà poi discusso durante un orale durante il quale dovrete presentarmi il progetto, ciascun membro del gruppo dovrà descriverne una parte e io farò domande e commenti sul progetto. Per quanto riguarda i dati e l'argomento del progetto, ci sono due modalità: una modalità in cui vi vengono forniti dei dati su cui sviluppare il progetto e una modalità libera, che dovrà essere concordata con me durante un ricevimento.

Librerie consentite

È consentito esclusivamente l'utilizzo di pacchetti Python visti a lezione:

- Numpy;
- Pandas;
- Matplotlib;
- Seaborn.

Oltre a questi, è sempre consentito l'utilizzo dei pacchetti della libreria di sistema Python (os, sys, re, etc).

Progetto: requisiti minimi

Sia che scegliate di lavorare sui dati che vi ho fornito, sia che scegliate un progetto a scelta, dovrete rispettare i seguenti requisiti minimi:

- Elaborazione automatica di testi, che includa la loro tokenizzazione (senza usare librerie di NLP);
- L'utilizzo di un dataset in formato CSV o JSON;

- Elaborazione di statistiche sui dataset (es: media di una distribuzione);
- Visualizzazioni grafiche dei risultati;
- Sviluppo di almeno un'euristica legata al dataset linguistico.

Oltre a questi requisiti, il notebook deve contenere un commento delle analisi effettuate in corrispondenza della presentazione dei risultati o dei grafici (es: se calcolate la media dei valori di una lista, scrivete che cosa rappresenta e commentate il risultato).

Progetto a scelta

Per quanto riguarda i progetti a scelta, vi lascio totale libertà di scegliere un argomento che vi interessa e i dati su cui lavorare, fermi restandi i requisiti minimi. Se avete idee ma ci sono difficoltà nel reperire i dati contattatemi e vi darò una mano nel trovare i dati. Prima di iniziare a lavorare al progetto, tuttavia, dobbiamo concordare un ricevimento, in modo che vi possa dare un riscontro rispetto al carico di lavoro richiesto.

Progetto su dati forniti da me

Un'altra modalità è quella di utilizzare i dati forniti da me. Si tratta in particolare di un file `dati-progetto.zip` che potete trovare su virtuale.unibo.it e che contiene documentazione su come interpretare i file nella forma di un file README contenuto nell'archivio. Avrete accesso a due dataset:

Dati ISTAT

Un dataset dell'ISTAT che fornisce informazioni sul numero di residenti nati all'estero o che hanno cittadinanza straniera in ciascun comune e ripartizione territoriale (regioni, province, macroaree). Oltre a questi dati, che vengono forniti su base annua dal 2002 al 2025, vi viene fornito un file che contiene i codici identificativi e varie informazioni su ciascun comune.

Change-IT

Si tratta di un'ampia collezione di testi di articoli del quotidiano Repubblica, che sono stati estratti nell'ambito di un task¹ della campagna di valutazione EVALITA nel 2020. Viene fornito un file in formato CSV che contiene il titolo dell'articolo, il testo completo dell'articolo e l'URL a cui si trova.

¹<https://sites.google.com/view/change-it>

La traccia

Il progetto riguarda una comparazione fra i dati reali (ISTAT) e la frequenza di utilizzo di termini legati a persone migranti negli articoli online (ad esempio: la parola "francese" appare più o meno frequentemente di quanto non siano i cittadini francesi in Italia?). Avete a disposizione varie informazioni, da cui potete trarre delle domande da analizzare tramite i dataset:

- Sesso: le varianti maschili e femminili sono distribuite nella lingua come nella società? Oppure osserviamo delle discrepanze?
- Geografia: quali regioni, province, aree, presentano le maggiori discrepanze fra i dati ISTAT e la lingua?
- Anni: ci sono variazioni sostanziali nelle statistiche per i vari anni?

Poiché il numero di nazionalità è ampio, vi viene richiesto di selezionarne alcune (minimo 5).

Euristiche

Poiché non avete accesso a librerie di elaborazione del linguaggio naturale sofisticate, non potrete accedere ad alcune informazioni sui testi. Ad esempio, non è possibile capire se la parola "francese" è un nome o un aggettivo, se si riferisce alla lingua francese o alla nazionalità.

Per questa ragione, siete incoraggiati a esaminare le parole associate alle nazionalità da voi scelte e sviluppare delle semplici euristiche, ovvero dei criteri imperfetti per discriminare queste situazioni e giustificare la loro adozione (es: escludi la parola "francese" se è preceduta da "lingua").

Anche se sceglierete di utilizzare i dati che vi fornisco per il progetto, pensate a quali aspetti dei dati sono per voi più interessanti. La scelta di nazionalità, tipi di analisi, euristiche è vostra. Siate creative e creativi!

Scadenze

Le scadenze per gli appelli sono le seguenti:

Mese	Consegna progetto	Appello
Giugno	10/06/2026	17/06/2026
Luglio	08/07/2026	15/07/2026
Settembre	26/08/2026	02/09/2026