



ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Progetto d'esame

Michele Corazza

CIRSFID – ALMA AI, Department of Legal Studies, University of
Bologna

Modalità d'esame

Progetto a gruppi (3-4 persone): un progetto Python. Vi verrà richiesto il **codice del progetto**, da consegnare 7 giorni prima della discussione orale. Discuteremo del progetto durante un esame orale.

Il progetto vale il 50% del voto totale, la sufficienza è di 18 punti e il massimo è di 33 punti.



Progetto: due modalità

- **Modalità a vostra scelta:** potrete scegliere un argomento a vostra scelta. Se avete bisogno di aiuto per reperire dati ne possiamo discutere assieme. L'argomento va **concordato con me**, dovrete venire a ricevimento
- **Modalità su dati forniti:** vi fornisco io due dataset e una traccia generica, dovrete effettuare analisi a vostra scelta all'interno di questa traccia.



Progetto: consegna

Dovrete produrre un progetto nel formato di un notebook Jupyter. Potete anche creare pacchetti a vostra scelta.

Una settimana prima del progetto dovete inviarmi via e-mail (michele.corazza2@unibo.it):

- Un **archivio zip** che contiene la cartella del progetto contenente tutto il codice e tutti i dati utilizzati;
- I nomi dei componenti del gruppo.



Progetto: librerie consentite

Potete utilizzare **esclusivamente** le librerie viste a lezione:

- NumPy
- Pandas
- Matplotlib
- Seaborn

Oltre a queste librerie extra, è sempre possibile l'utilizzo delle librerie di sistema di Python (os, sys, re, csv, json, etc).



Progetto: requisiti minimi

Il progetto, sia esso a scelta o sui dataset forniti, deve avere una serie di funzionalità minime:

- Elaborazione di testi, che comprenda la **tokenizzazione**;
- L'utilizzo di almeno un dataset in formato JSON e/o CSV;
- Elaborazione (e stampa a video) di statistiche sui dataset;
- Utilizzo di librerie di visualizzazione grafiche (matplotlib, seaborn) per visualizzare i risultati
- Sviluppo di almeno un'euristica legata al dataset linguistico.

Oltre a questi requisiti, il notebook deve contenere un commento delle analisi effettuate in corrispondenza della presentazione dei risultati (eg calcoliamo il valore medio di due liste, commentiamo la differenza osservata dopo aver fatto il calcolo e stampato i valori).



Progetto su dati forniti: due dataset

- **ISTAT:** Un dataset che fornisce informazioni sul numero di residenti nati all'estero o che hanno cittadinanza straniera in ciascun comune e ripartizione territoriale (regioni, province, macroaree). Oltre a questi dati, che vengono forniti su base annua dal 2002 al 2025, vi viene fornito un file che contiene i codici identificativi e varie informazioni su ciascun comune.
- **Change-IT:** Si tratta di un'ampia collezione di testi di articoli del quotidiano Repubblica, che sono stati estratti nell'ambito di un task della campagna di valutazione EVALITA nel 2020. Viene fornito un file in formato CSV che contiene il titolo dell'articolo, il testo completo dell'articolo e l'URL a cui si trova.



Progetto su dati forniti: la traccia

L'idea è quella di comparare la percentuale di persone nate o con cittadinanza straniera secondo il dataset ISTAT e vedere come queste nazionalità sono distribuite negli articoli di Repubblica. Avete a disposizione varie informazioni, da cui potete trarre delle domande da analizzare tramite i dataset, ad esempio:

- **Sesso:** le varianti maschili e femminili sono distribuite nella lingua come nella società? Oppure osserviamo delle discrepanze?
- **Geografia:** quali regioni/province/macroaree presentano le maggiori discrepanze fra le nazionalità e la lingua?
- **Anni:** ci sono variazioni sostanziali nelle statistiche per i vari anni? Attenzione: gli anni di pubblicazione degli articoli vanno estratti dagli URL.

Poiché il numero di nazionalità è ampio, vi viene richiesto di selezionarne solo alcune (minimo 5).



Nota metodologica: non è un corso di Elaborazione del Linguaggio naturale

Poiché non avete accesso a librerie di elaborazione del linguaggio naturale, non potrete accedere ad alcune informazioni sui testi. Ad esempio, non sarà possibile per voi utilizzare informazioni sulla categoria grammaticale per sapere se "francese" è usato come nome o aggettivo!

Per questa ragione, siete incoraggiati a esaminare le parole associate alle professioni da voi scelte e sviluppare delle semplici **euristiche**, ovvero dei criteri imperfetti per discriminare queste situazioni e giustificare la loro adozione (es: escludi la parola "francese" se è preceduta da "consolato", usa parole presenti negli articoli per determinarne il contenuto). La scelta delle parole associate alle nazionalità va anch'essa giustificata.

Quanto tempo impiegare per sviluppare euristiche e quanto tempo impiegare per l'analisi dei dati è una vostra scelta. Ovviamente se svilupperete sistemi complessi per discriminare fra parole che rappresentano nazionalità potrete spendere meno tempo nell'analisi dei dati ISTAT, e viceversa.



Siate creative/i!

Anche se vi fornisco due dataset e una traccia di progetto, cercate di pensare quali aspetti dei dataset siano interessanti **per voi!** Lo stesso vale per la scelta delle nazionalità, dei fattori da osservare, delle euristiche da sviluppare.

Anche usando i dati da me forniti, potrebbero venirvi in mente delle domande diverse da quelle a cui ho pensato io. Sentitevi liberi di sperimentare e fatevi guidare dalla vostra curiosità.



Appelli

Mese	Consegna progetto	Appello
Giugno	10/06	17/06
Luglio	08/07	15/07
Settembre	26/08	02/09

Esploriamo i dati (e la documentazione)

